

이동물체 탐지를 위한 레이더 데이터의 거리-도플러 클러스터링 기법

김성준¹⁾ · 양동원^{*,1)} · 정영현¹⁾ · 김수진¹⁾ · 윤주홍¹⁾

¹⁾ 국방과학연구소 국방무인기술센터

Range-Doppler Clustering of Radar Data for Detecting Moving Objects

Seongjoon Kim¹⁾ · Dongwon Yang^{*,1)} · Younghun Jung¹⁾ · Sujin Kim¹⁾ · Joohong Yoon¹⁾

¹⁾ Defense Unmanned Technology Center, Agency for Defense Development, Korea

(Received 15 May 2014 / Revised 6 September 2014 / Accepted 7 November 2014)

ABSTRACT

Recently many studies of Radar systems mounted on ground vehicles for autonomous driving, SLAM (Simultaneous localization and mapping) and collision avoidance are reported. In near field, several hits per an object are generated after signal processing of Radar data. Hence, clustering is an essential technique to estimate their shapes and positions precisely. This paper proposes a method of grouping hits in range-doppler domains into clusters which represent each object, according to the pre-defined rules. The rules are based on the perceptual cues to separate hits by object. The morphological connectedness between hits and the characteristics of SNR distribution of hits are adopted as the perceptual cues for clustering. In various simulations for the performance assessment, the proposed method yielded more effective performance than other techniques.

Key Words : RADAR(레이더), Clustering(클러스터링), Pre-Clustering(사전클러스터링), Range-Doppler Image(거리-도플러 영상), Partial Plot(부분플롯)

1. 서론

영상 카메라(camera), 라이더(LIDAR : Light Detection And Ranging), 레이더(RADAR : Radio Detection And Ranging)와 같은 지형/지물에 대한 3차원 정보를 획득

할 수 있는 원격센싱(remote sensing) 기술이 발전함에 따라, 이를 차량에 탑재하여 무인자율주행이 가능한 무인지상차량(UGV : Unmanned Ground Vehicle)에 대한 많은 연구가 이루어지고 있다.

이동물체를 탐지하기 위해서는 레이더로부터 출력된 신호를 처리하여 신호세기(SNR : Signal to Noise Ratio)로 이루어져 있는 비디오 영상을 생성한다. 생성된 비디오 영상에서는 물체로부터 후방산란된 신호

* Corresponding author, E-mail: dongwoni@add.re.kr
Copyright © The Korea Institute of Military Science and Technology

세기값을 갖는 픽셀 뿐 만 아니라 배경 클러터(clutter) - 배경으로부터 되돌아온 신호값을 갖는 픽셀들이 포함되어 있다. 이러한 클러터는 CFAR(Constant False Alarm Rate) 기법을 이용하여 제거된다. 인접한 주위 픽셀들의 신호세기 대푯값을 임계치로 사용하여, 이보다 낮은 신호세기 값을 갖는 픽셀들은 클러터 픽셀로 구분하고, 높은 픽셀들을 물체 픽셀(hit 픽셀)로 탐지한다. 그리고 탐지된 hit 픽셀의 거리, 방위각, 속도 차원(domain)의 인덱스(index)를 이용하여 표적의 거리, 방위각, 속도값을 계산한다^[1-3].

그러나 수 km 떨어진 장거리 이동물체는 거의 1~2개의 hit 픽셀이 생성되지만, 지상 이동체에 탑재되어 100m 이내의 물체를 탐지하는 근거리 레이더의 경우 물체는 거리에 따라 수 개의 hit 픽셀로 나타날 수 있다. 따라서 이동물체를 탐지하기 위한 근거리 레이더 데이터 처리에서 이동물체별로 hit 픽셀들을 그룹화하는 클러스터링 기법이 필요하다.

CFAR 기법을 거쳐 출력되는 hit 픽셀은 거리, 도플러(속도), 방위각 도메인상의 위치(pixel index)와 신호세기 값을 가지고 있다. 즉, 전체 hit 데이터는 거리-속도-방위각 차원의 3차원 영상을 의미한다.

Hit 클러스터링은 Fig. 1과 같이 거리-도플러 차원에서 hit 픽셀을 그룹화하는 거리-도플러 클러스터링 단계와 거리-도플러 차원에서 그룹화된 부분플롯(partial plot)를 다시 방위각 차원에서 그룹화하여 플롯(plot)을 생성하는 방위각 클러스터링 단계로 구성된다^[5].



Fig. 1. Hit clustering of RADAR data

본 연구에서는 hit 클러스터링에서 첫 번째 단계인 거리-도플러 클러스터링 방법을 제안하고자 한다. 거리-도플러 클러스터링은 방위각 빔 단위로 수행한다. 먼저, 각 방위각 빔 별로 생성된 hit로부터 거리-도플러 영상을 만든 후, 사전에 정의된 규칙으로 hit 픽셀들을 그룹화 한다. 정의된 규칙은 hit 픽셀들을 같은 물체에 의해 생성된 것들끼리 묶어 줄 수 있는 인지적 단서(perceptual cues)를 의미하며, 이는 하나의 물체로부터 생성된 hit 픽셀에서 나타나는 특성에 기반

한다. 클러스터링에서 사용하는 인지적 단서는 hit 픽셀간 유클리디언 거리(euclidean distance)에 기반한 인접특성과 hit 픽셀의 신호세기 분포특성이 있다.

2. 방법론

2.1 선행연구 고찰

기존의 레이더 시스템은 주로 장거리 이동물체를 탐지/추적하기 위한 목적으로 개발되어 왔기 때문에 hit 클러스터링 기법에 대한 선행연구가 미비하였다. 그러나 근래에는 충돌방지 목적으로 지상 차량에 탑재되는 카레이더(car radar)가 개발됨에 따라서 이동물체에 의해 나타나는 다수의 hit 픽셀을 클러스터링 하기위한 연구가 많이 이루어지고 있다.

Hit 클러스터링을 위한 기존의 선행연구를 살펴보면, 연결성 기반 레이블링 기법(Connected Components Labeling or Flood Fill), K-means 클러스터링 및 Knee-point 기법, 가우시언 프로파일(gaussian profile) 기반 클러스터링 기법 등이 있다.

연결성 기반 레이블링은 컴퓨터 비전(computer vision) 분야에서 이진영상(binary image)을 분석하기 위한 레이블링(labeling) 기법 중 하나로써, 서로 연결되어 있거나 인접한 픽셀들을 하나의 레이블로 묶어주는 방식으로 클러스터링을 수행한다^[4,5].

그러나 이 기법은 2개 이상의 물체들이 서로 인접한 경우, hit 픽셀들을 하나의 클러스터로 그룹화하는 과소분할(under segmentation or merged false alarm)이 발생한다.

K-means 클러스터링은 임의의 n 개 객체(hit 픽셀)들을 k 개의 집단(클러스터)으로 그룹화하는 기법이다^[7-12]. 이 방법은 클러스터 중심벡터와 클러스터를 구성하는 객체 요소들의 벡터차이의 분산이 최소화 되도록 객체들을 그룹화 한다. 그러나 클러스터의 개수 k 를 알고 있어야 하며, 임의(random)로 생성하는 k 개의 초기 클러스터 중심벡터에 따라 클러스터 결과가 상이할 수 있다. 또한 인접한 클러스터들의 형태, 크기에 따라 hit 픽셀들이 오분류되는 현상이 발생한다.

클러스터의 개수 k 를 결정하기 위해 개발된 기법으로 Knee-point 알고리즘이 있다. 먼저 클러스터 개수가 1~ n 개라고 할 때, 각각 K-means 클러스터링을 수행하고 이에 대한 NMSOS(Normalized Minimized Sum Of Square) error가 급격하게 변화하는 지점을 찾음으로써

클러스터 개수를 결정한다. 그러나 클러스터들의 분포와 크기에 따라 성능의 한계가 발생한다.

가우시언 프로파일 기반 클러스터링 기법은 서로 인접한 물체들에 의해 발생된 hit 픽셀들을 잘 분리함으로써 탐지된 물체의 위치정확도를 높이기 위해 개발되었다^[5]. 먼저 화소값(신호세기)이 높은 픽셀 순서대로 픽셀을 중심으로 가우시언 모양의 프로필을 생성한다. 그리고 프로필 영역 내에 해당하는 픽셀들을 하나의 클러스터로 그룹화하고 제거한다. 이 방법은 서로 인접한 클러스터를 효율적으로 분리할 수 있다. 그러나 프로필 모델 변수(parameter)에 민감하여, 데이터 특성을 고려한 정밀한 프로필 모델링이 필요하다.

CFAR로부터 출력된 영상에서 클러스터링을 수행하기 위한 기존의 선행연구들을 살펴보면 픽셀간의 인접성과 거리를 이용한 클러스터링 기법과 하나의 물체에 대한 hit 픽셀들의 신호세기 분포를 고려한 프로필 모델기반의 기법이 있음을 확인하였다. 전자의 경우 인접한 두 개 이상의 물체에서 나타난 hit 픽셀들을 잘 분리하지 못하였으며, 후자는 클러스터링 결과 가 모델변수에 민감하다는 문제가 있다.

이에 본 연구에서는 입력변수에 민감하지 않으면서 인접한 물체 hit 픽셀들을 잘 분리할 수 있는 기법을 제안하고자 한다. 이를 위해 hit 픽셀간 인접성과 물체 hit 픽셀들의 신호세기 분포 특성을 이용하였다.

2.2 제안 클러스터링 기법

본 연구에서 제안하는 거리-도플러 클러스터링 방법은 선행연구에서 언급된 연결성 기반 레이블링 기법중 하나인 플러드필(flood fill) 알고리즘과 하나의 이동물체에 의해 거리-도플러 차원에서 나타나는 hit 픽셀들의 신호세기 분포특성을 이용하였다.

CFAR 처리를 거쳐 출력된 hit 픽셀들의 신호세기 값은 거리-도플러 도메인에서 종형(bell shape)의 분포 특성을 갖는다^[5]. 이는 레이더 영상에서 나타나는 물체 신호의 특성에 따른 것으로, 이 신호 특성에 대한 모델을 살펴보면 다음과 같다. 거리-도플러 영상에서 (rc , kc) 위치에 있는 물체에 의해 발생하는 hit 픽셀의 신호세기 분포는 식 (1)~(4)의 모델을 따른다^[5]. 여기에서 r 은 거리셀, k 는 도플러셀이며, S_{min} 는 CFAR에서 임계치에 의해 계산되는 상대적인 신호세기 값이다. $PD(k)$ 와 $PR(r)$ 은 각각 도플러, 거리 방향의 신호세기 프로필을 의미한다. 식 (2)에서 sf 는 물체에 의한 거

리방향의 프로필 퍼짐정도를 의미하며, 식 (4) σ_{filter} 는 도플러방향의 프로필 퍼짐정도를 나타내는 값이다. ND 와 PRF 는 각각 도플러 필터수와 펄스반복률을 의미한다.

$$S_{dB}(r, k) = \max(10 \log_{10}(PD(k) \cdot PR(r)) + S_{min}, 0) \quad (1)$$

$$PR(r) = \max(\exp(-(sf \cdot (r - rc))^4), 10^{-10}) \quad (2)$$

$$PD(k) = \exp\left(-\frac{(k - kc)^2}{2\sigma_{doppler}^2}\right) \quad (3)$$

$$\sigma_{doppler}^2 = \left(\frac{19.35 \times ND \times 4}{PRF}\right)^2 + \sigma_{filter}^2 \quad (4)$$

본 연구에서는 이러한 신호세기 값의 분포 특성을 이용한다. 먼저 탐지된 물체에 의해 발생된 hit 픽셀 중에서 국부적으로 가장 높은 신호세기 값을 지닌 hit 픽셀을 탐색한다. 그리고 플러드필 알고리즘을 이용하여 탐색된 hit 픽셀을 중심으로 이웃픽셀들 중에서 중심픽셀보다 작은 신호세기 값을 갖는 픽셀들만 탐색하여, 중심 픽셀과 같은 클러스터 번호를 부여하는 방식으로 영역확장(region growing)을 시도한다. 이러한 영역확장 과정은 재귀적(recursive)으로 수행한다.

제안된 방법의 전체 과정은 Fig. 2와 같이 1) 노이즈 제거(noise reduction), 2) 국부적 피크픽셀 탐지(local peak pixels detection), 3) 영역확장(region growing)으로 구성된다.

1) 노이즈 제거 단계에서는 레이더 송수신 및 신호 처리 모듈에서 발생하는 신호잡음에 의해 발생된 거리-도플러 영상의 노이즈를 제거한다. 이는 다음 단계인 국부적 피크픽셀(local peak pixel)을 탐지할 때, 영상 노이즈에 의한 오탐지율(false alarm rate)을 줄이기 위함이다. 이를 위해 Fig. 3과 같은 가우시언 필터(gaussian filter)를 사용하여 영상 노이즈에 의한 영향을 제거한다. 주어진 영상(I)과 가우시언 필터 커널(H)이 있을 때 영상필터링은 식 (5)~(6)과 같다. 가우시언 필터를 적용함에 있어서 필터 사이즈(size)와 표준편차(σ) 값에 따라 노이즈 억제 정도가 결정된다. 따라서 노이즈의 발생 패턴과 양 등의 특성을 고려해야하기 때문에 실험적으로 결정하며, 본 연구에서는 표준편차가 1인 3×3사이즈의 가우시언 필터를 적용하였다.

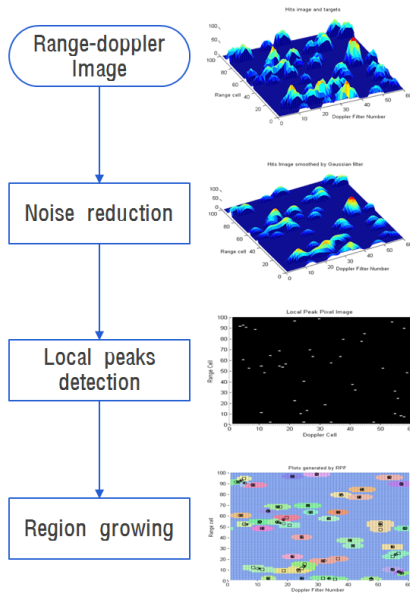


Fig. 2. Proposed method of hit clustering in range-doppler domains

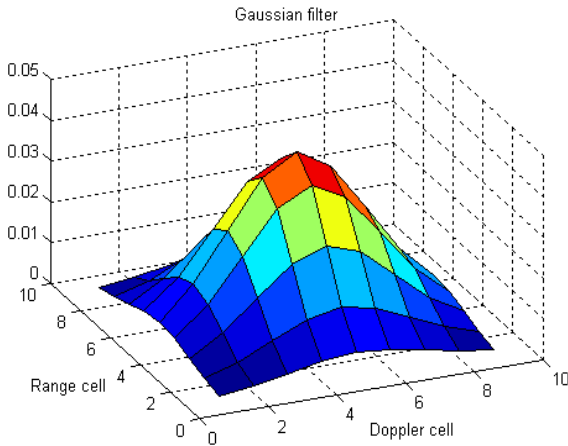


Fig. 3. Example of Gaussian filter for noise reduction

$$f(i, j) = I * H = \sum_k \sum_l I(k, l) H(i-k, j-l) \quad (5)$$

$$H(i, j) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{((i-k-1)^2 + (j-k-1)^2)}{2\sigma^2}\right) \quad (6)$$

2) 국부적 피크픽셀 탐지에서는 노이즈가 제거된 거리-도플러 영상에서 국부적으로 신호세기 값이 높은

hit 픽셀을 탐지한다. 이를 위해, 영상에서 각 행(row)과 열(column) 방향의 프로파일(profile)에서 피크 픽셀을 찾고, 행 방향 피크영상과 열 방향 피크영상에 AND 연산자를 적용하여, 국부적인 피크영상을 생성한다. 탐지된 피크 픽셀은 영역확장 단계에서 초기 중심픽셀이 되며, 이를 중심으로 클러스터링을 수행한다.

3) 영역확장 단계에서는 탐지된 국부적 피크픽셀을 중심으로 인접한 이웃 hit 픽셀(neighborhood pixel)들을 클러스터에 포함시키면서 그룹화를 수행한다. 그룹화를 통한 영역확장은 Fig. 4와 같이 플러드필 알고리즘을 이용하여 피크 픽셀을 시작(seed pixel)으로 재귀적으로 인접한 주위 픽셀을 클러스터 영역으로 성장시킨다.

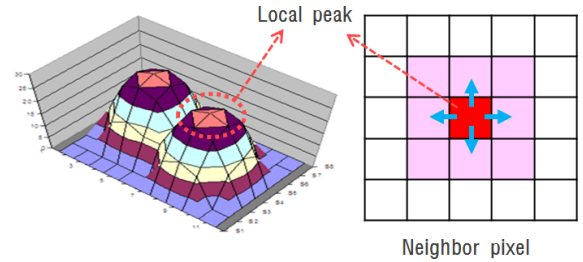


Fig. 4. Search neighbor pixels with 4 directions for region growing

Fig. 5는 본 연구에서 제안한 영역확장 방법에 대한 도식이다. 하나의 클러스터에서 탐색된 피크픽셀을 입력했을 때, 그룹화 과정은 다음과 같이 수행된다. 먼저 입력된 피크픽셀을 중심으로 이웃 hit 픽셀을 탐색한다. 탐색된 이웃 hit 픽셀에 대하여 정해진 2가지 조건을 만족하는 픽셀을 클러스터에 포함시킨다.

이러한 그룹화 과정은 단위 국부적 피크픽셀마다 재귀적으로 반복수행 된다. 탐색된 이웃 hit 픽셀에 대한 그룹화 여부를 결정하는 첫 번째 조건은 이웃 hit 픽셀과 중심 hit 픽셀의 신호세기 값이다. 이웃 hit 픽셀의 신호세기 값이 중심 픽셀 보다 낮다면, 두 픽셀 모두 같은 물체에 의해 발생한 경우이므로 그룹화를 수행한다. 만약 이웃 hit 픽셀의 신호세기 값이 중심 픽셀 보다 높다면, 이웃 hit 픽셀과 중심 hit 픽셀은 서로 다른 물체에 의해 발생된 경우이므로 그룹화를 수행하지 않는다.

두 번째 조건은 탐색된 이웃 hit 픽셀이 첫 번째 조건을 만족하지만 이미 다른 클러스터에 그룹화된 경

우이다. 이는 이웃 hit 픽셀이 서로 인접한 두 클러스터 경계에 위치할 때 발생한다. 인접한 두 클러스터 경계에 위치한 hit 픽셀은 두 클러스터의 국부적 피크 픽셀까지의 유클리디안 거리(euclidean distance)를 비교하여 가까운 클러스터로 그룹화를 수행한다.

Fig. 6은 본 연구에서 사용한 영역확장 알고리즘의 순서도이다. 먼저, 주어진 영상(I)와 하나의 피크픽셀(x, y), 생성할 클러스터 번호(ID)가 주어질 때, 피크픽셀을 중심으로 4방향의 인접픽셀의 DN(digital number) 값이 0보다 크고 피크픽셀 DN보다 작은지를 검사한다. 그리고 조건을 만족시키는 인접 픽셀은 클러스터 영상(C)에서 해당 위치의 픽셀 값에 클러스터 번호를 부여한다. 다만 두 개 이상의 클러스터가 중첩된 영역에 해당하는 픽셀의 경우 각 클러스터까지의 거리가 최소가 되는 클러스터 번호를 부여하였다. DN이 0인 픽셀은 물체에 의해 hit되지 않은 널(null)픽셀이며, 이는 클러스터의 경계를 결정한다.

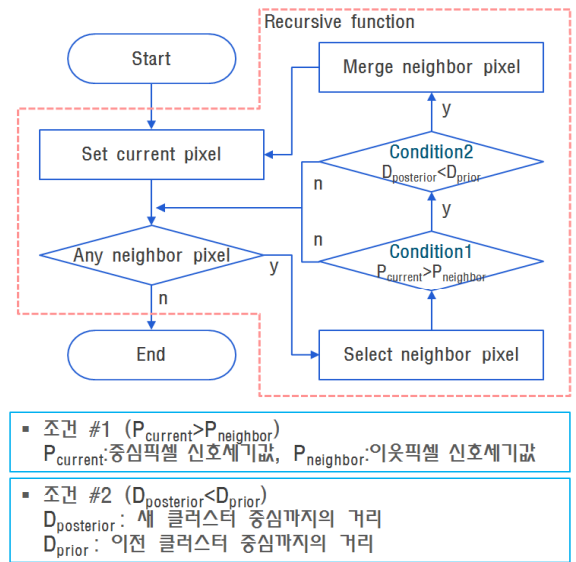


Fig. 5. Region growing algorithm including 2 conditions

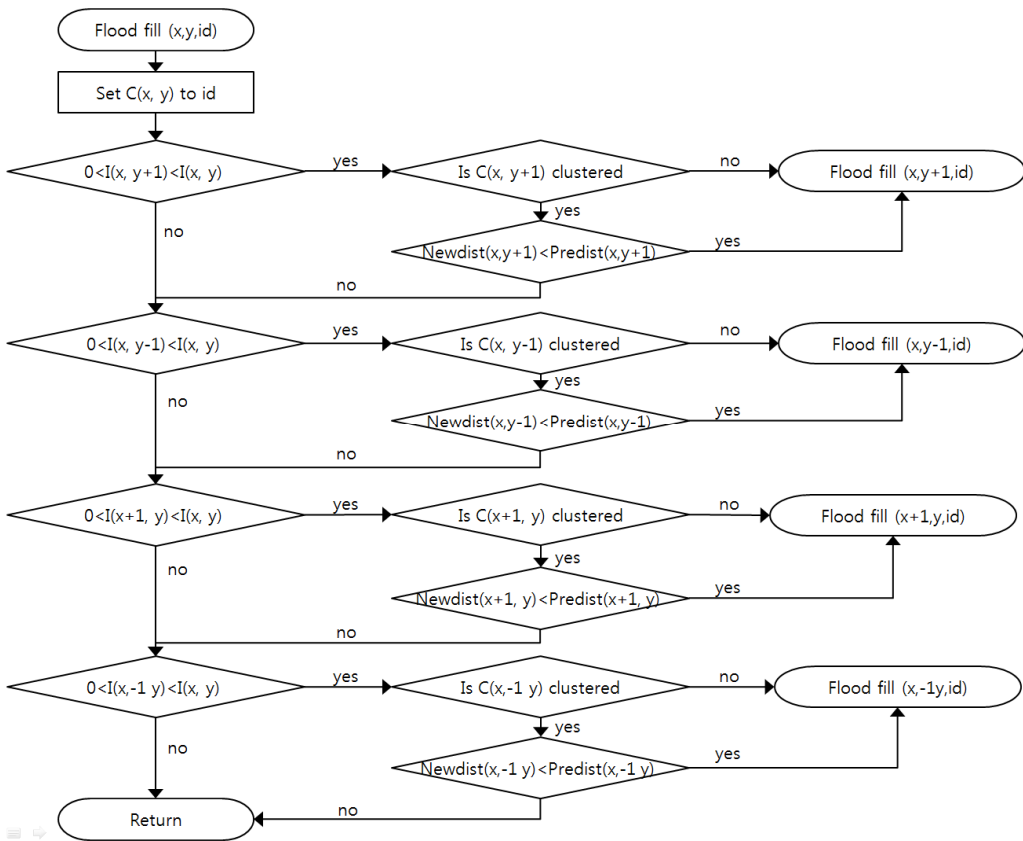


Fig. 6. Flow chart of region growing algorithm

3. 실험 및 결과

본 장에서는 제안된 거리-도플러 클러스터링 기법의 성능을 검증하기 위한 실험을 수행하였다. 알고리즘의 성능 분석을 위해서는 실제 레이더 시스템으로부터 획득한 데이터를 적용해보는 것이 합리적이지만, 본 연구에서는 물체 개수, 위치 등을 임의의 시나리오로 만들어서 연구 결과의 유효성을 검증하기 위해, 모의 생성한 거리-도플러 영상을 이용하였다. 시뮬레이션 데이터를 활용하면 물체 개수, 위치 등의 다양한 시나리오를 임의로 생성할 수 있다.

전체 실험과정은 다음과 같다. 먼저, 임의의 위치에 존재하는 물체에 대한 거리-도플러 모의 영상을 생성하고, 제안된 알고리즘을 적용해보았다. 그리고 실험 결과를 분석하고, 기존 클러스터링 방법들과 비교해 보았다.




Fig. 7. Simulated radar image in range-doppler domains

3.1 데이터 시뮬레이션

데이터 시뮬레이션은 식 (1)에서 기술된 hit 픽셀의 신호세기 분포특성 모델을 이용한다. 전체 60×100 pixel 크기의 영상위에 50개의 물체를 생성하였다. 각 물체의 위치는 랜덤하게 결정하였으며, 신호세기 값도 20~60 dB 범위 내에서 랜덤으로 결정하였다. 그리고 신호잡음은 평균이 0이고, 표준편차가 5 dB인 정규분포(normal distribution)를 따르는 우연오차(random noise)를 생성하여 추가하였다. Fig. 7은 모의 생성된 거리-도플러 영상이며, Fig. 8은 거리-도플러 영상위에 모의 생성된 물체의 모습을 네모 마커로 보여주고 있다.

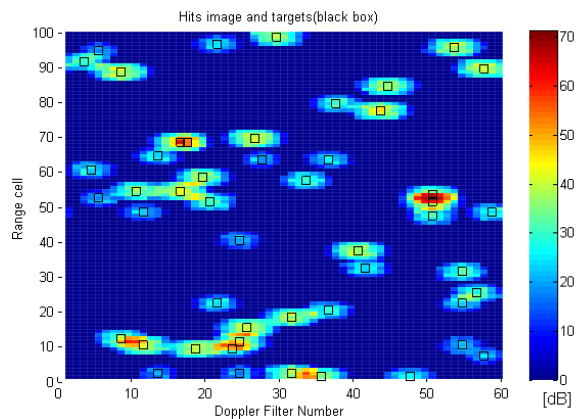


Fig. 8. Range-doppler image and locations of targets (□ marker)

3.2 적용실험 및 결과

가우시언 필터(5×5)에 의해 평활화(smoothed)된 거리-도플러 영상은 Fig. 9와 같다. 이 영상으로부터 국부적인 물체 피크픽셀을 탐지하기 위해, Fig. 10(a), (b)과 같이 각 행과 열방향의 프로필에서 피크 픽셀을 찾고, 두 피크영상의 AND 연산자를 적용하여 Fig. 10(c)와 같이 총 43개의 물체 피크픽셀을 추출하였다.

탐지된 피크픽셀을 입력으로 영역확장 알고리즘을 수행시킨 결과 Fig. 11과 같은 클러스터 영상(부분플롯, partial plot)을 생성하였다.

전체 50개의 물체로 생성된 거리-도플러 영상을 입력으로 총 43개 물체 클러스터가 생성되었다. Fig. 11에서 네모 마커(□)는 데이터 시뮬레이션에서 모의 생성한 물체의 위치이며, 별 마커(*)는 탐지된 피크픽셀을 나타낸다. 그리고 생성된 각 클러스터의 픽셀들의 중심위치를 원 마커(○)로 표시하였다.






Fig. 9. Smoothed range-doppler image by gaussian filter

출력된 클러스터들은 크게 3개로 구분할 수 있다. 1) 첫째는 실제 물체에 의해 발생한 hit 픽셀들끼리 그룹화된 클러스터로서, 물체와 클러스터가 1:1로 대응되는 경우이다. 2) 둘째는 서로 다른 물체에 의해 hit된 픽셀들이 하나로 그룹화된 클러스터로, 물체와 클러스터가 N:1로 대응되는 경우이다. 3) 마지막으로 세 번째는 하나의 물체에 의해 발생한 hit 픽셀들이지만 두 개 이상의 클러스터로 그룹화된 경우이며, 이는 물체와 클러스터가 1:N 대응된다. 첫 번째 경우의 클러스터는 hit 픽셀들이 합리적으로 클러스터링 되었음을 의미하지만, 두 번째와 세 번째 경우는 hit 픽셀들이 오분류 되어 나타나는 현상이다.

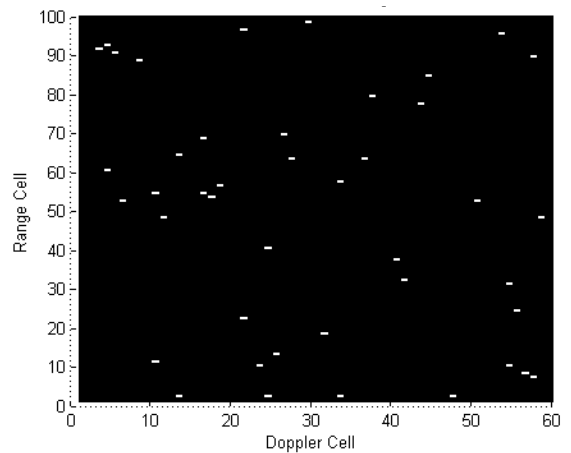
본 연구에서는 두 번째의 경우를 “과소분할(under-segmentation)”, 세 번째의 경우를 “과대분할(over-segmentation)”이라 정의하였다^[6].



(a) peak profile image in range



(b) peak profile image in doppler



(c) Local peak profile image

Fig. 10. Peak profile images

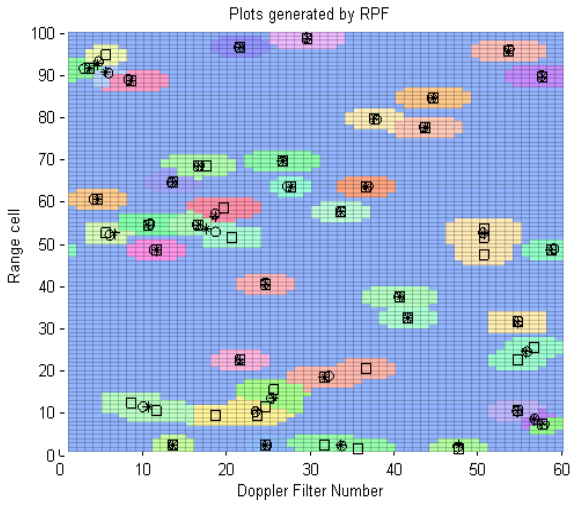


Fig. 11. Target clusters around the detected peak pixels (\square : target location, $*$: peak pixel, \circ : cluster center)

전체 생성된 43개 클러스터에 대하여 과대/과소분할된 클러스터들을 분석하였다. 그 결과, 2개는 Fig. 12(a)와 같이 동일한 물체에 의해 발생한 hit 픽셀들이 다수의 클러스터로 과대분할 되었다. 그리고 9개의 클러스터는 Fig. 12(b)와 같이 각각 서로 다른 물체에 의해 발생한 hit 픽셀들이 하나의 클러스터로 과소분할 되었다.

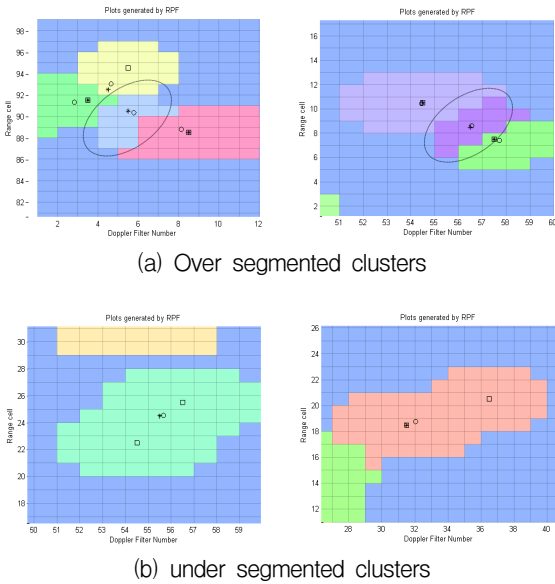


Fig. 12. Over/under segmented clusters

과소/과대분할의 원인은 모두 클러스터간 인접거리가 매우 짧기 때문으로 나타났다. Fig. 13은 두 클러스터의 인접거리에 따른 도플러방향의 프로필을 보여주고 있다. Fig. 13(a)와 (b)를 살펴보면, 인접한 두 클러스터에서는 각기 다른 피크지점이 존재하지만, 인접거리가 점점 줄어들어 따라 Fig. 13(c)와 같이 두 클러스터가 중첩됨에 따른 새로운 피크지점이 나타났다. 그리고 두 클러스터의 거리가 더 가까워짐에 따라 Fig. 13(d)와 같이 하나의 클러스터처럼 신호세기 분포가 나타났다.

Fig. 12(a)의 과대분할된 클러스터의 경우는 Fig. 13(c)와 같이 인접한 두 클러스터 사이에 중첩으로 인한 새로운 클러스터가 발생하였기 때문이다. 그리고 Fig. 12(b)의 과소분할된 클러스터의 경우는 Fig. 13(d)와 같이 인접한 두 클러스터 사이에 중첩으로 인해 하나로 합쳐졌기 때문이다.


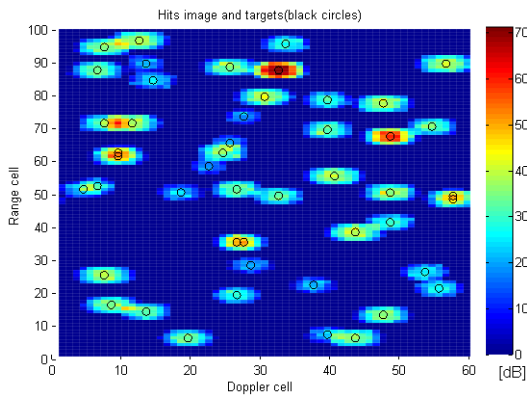


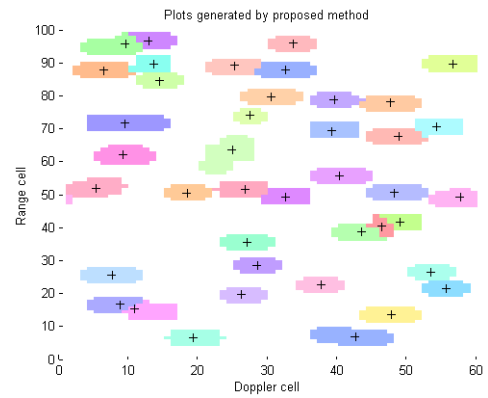
Fig. 13. Signal variations according adjacent distances

3.3 결과고찰

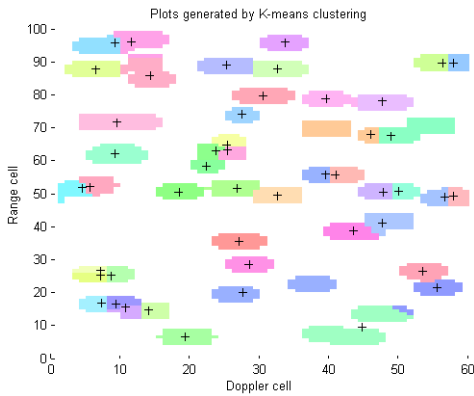
본 연구에서 제안한 클러스터링 기법의 성능을 판단하기 위해 앞에서 언급된 K-means 클러스터링 기법과 가우시안 프로파일 기반 방법, 연결성 기반 레이블링 기법을 구현하여 적용실험을 수행하였다. 그리고 Fig. 14와 같이 각 방법들의 결과를 비교하여 Table 1에 정리하였다.



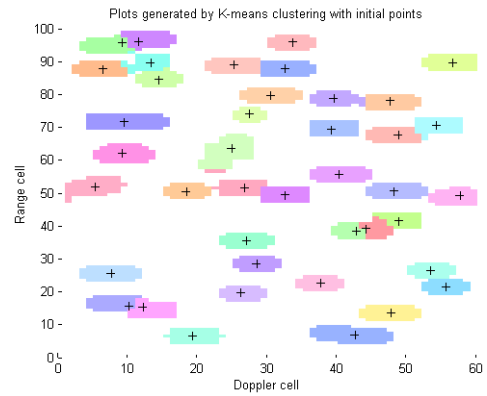
(a) Simulated range-doppler image
(○: target location)



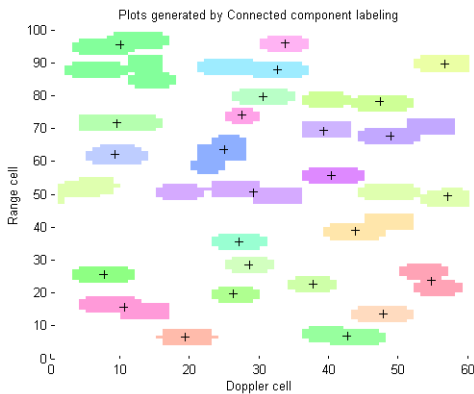
(b) Clusters generated by the proposed method
(+: cluster center)




(c) Clusters generated by K-means



(d) Clusters generated by K-means
with initial parameters



(e) Clusters generated by connected
component labeling



(f) Clusters generated by Gaussian
profile method

Fig. 14. Generated clusters by the proposed clustering method and existing algorithms

Table 1. Performance assessment result of the proposed method with the existing clustering algorithms

| | Proposed method | K-means | Connected Component Labeling | Gaussian profile |
|---------------------------------|-------------------------|---------------------------------------|-----------------------------------|--|
| No. of cluster | 41 | 48 | 28 | 57 |
| No. of correct clusters | 33 | 32 | 12 | 35 |
| No. of under segmented clusters | 7 | 8 | 16 | 7 |
| No. of over segmented clusters | 1 | 8 | 0 | 15 |
| note | no algorithm parameters | need the known parameters, randomness | can not separate adjacent targets | is sensitive to the algorithm parameters |

Fig. 14(a)는 모의 생성한 거리-도플러 영상이다. 검은색 원 마커는 물체의 위치를 표시하고 있다. 총 48개의 물체에 대하여 영상 시뮬레이션을 수행하였다.

Fig. 14(b)는 본 연구에서 제안한 기법을 적용하여 생성된 클러스터의 모습이다. 총 41개의 클러스터가 생성되었으며, 이 중 1개는 과대분할로 생성된 클러스터이며, 7개는 과소분할 되었다.

Fig. 14(c)는 K-means 클러스터링 기법에 적용한 결과이다. 클러스터 개수 값을 48로 입력하였기 때문에, 총 48개의 클러스터가 생성되었다. 그 중에 과대/과소분할된 경우는 각각 8개씩 나타났다. K-means 클러스터링은 초기 클러스터의 중심위치를 랜덤으로 생성한 후, 반복(iteration)을 통해 그 위치를 개선(update)한다. 이러한 알고리즘의 구조적인 특성 때문에 랜덤으로 생성되는 초기 위치에 따라 클러스터링 결과가 달라질 수 있다. 생성된 클러스터를 살펴보면, 랜덤으로 생성되는 초기 클러스터 위치에 따라 과대/과소분할된 경우를 확인할 수 있다.

Fig. 14(d)는 초기 클러스터의 위치를 랜덤으로 생성하지 않고, 제안된 클러스터링 기법에서 탐지된 피크 픽셀들을 입력한 K-means 클러스터링 결과이다. Fig. 14(c)와 비교했을 때, 초기 클러스터 위치에 따른 오류가 줄어들었다. 그러나 Fig. 14(a)와 비교해보면, 인접거리에 따라 과대분할된 클러스터의 크기가 커졌음을 확인할 수 있다. Hit 픽셀들이 가장 가까운 중심픽셀로 분류되기 때문이다. 이는 곧 물체로 탐지된 클러스터의 기하학적 정보(e.g. 형상, 위치)의 정확도를 떨어뜨리는 요인이 될 것으로 판단된다.

Fig. 14(e)는 연결성 기반 레이블링 기법을 적용해 생성된 클러스터이다. 하나의 클러스터 여부를 픽셀간 연결성으로 판단하기 때문에, 다수의 물체가 인접한 경우 하나의 클러스터로 나타나기 때문에 총 28개의 클러스터만 생성되었다. 그 중에서 16개가 과소분할로 나타났다.

Fig. 14(f)는 가우시언 프로필을 이용한 클러스터링 결과이다. 본 연구에서 제안된 방법의 결과(Fig. 14(a))와 비교했을 때 과대분할된 클러스터가 많이 나타났음을 확인할 수 있다. 이는 Hit 픽셀 신호세기 값이 신호 잡음에 의한 노이즈에 의해 가우시언 프로필보다 높은 경우에 별도의 클러스터로 분할되기 때문이다. 그리고 정의된 가우시언 프로필이 클러스터보다 큰 경우, 먼저 생성된 클러스터가 인접한 클러스터의 영역을 침범하는 현상이 나타났다. 과대분할된 클러스터 개수를 줄이기 위해서는 가우시언 프로필이 커야하며, 인접 클러스터의 영역을 침범하지 않도록 하기 위해선 프로필이 작아야 한다. 데이터의 특성에 따라 프로필을 잘 설계한다면, 좋은 결과가 출력될 것으로 판단된다.

4. 결 론

본 연구에서는 거리-도플러 영상에서 같은 물체에 의해 발생된 픽셀끼리 그룹화하는 사전 클러스터링 기법을 제안하였다. 제안된 방법은 먼저, 가우시언 필터링을 통해 영상 신호잡음 효과를 제거하고 국부적인 피크값을 갖는 픽셀을 탐색한다. 그리고 탐색된 픽셀

을 중심으로 재귀적으로 인접한 이웃픽셀의 hit 여부와 픽셀들의 신호세기 값을 검사하여 클러스터로 그룹화한다.

제안 방법의 성능을 분석하기 위해 시뮬레이션 영상을 모의 생성하고, 제안 방법과 기존 클러스터링 기법들의 적용 결과를 비교하여 보았다. 기존 기법에 비해 잘못된 클러스터의 개수가 확연히 줄어들었으며, 클러스터의 형상 또한 비교적 안정적으로 생성되었다.

K-means 클러스터링은 생성하고자 하는 클러스터의 개수를 입력해야 하며, 랜덤으로 생성되는 초기 중심 위치에 따라 결과가 달라지는 단점이 있다. 가우시언 프로파일의 경우 클러스터 결과가 프로파일 변수값에 민감하게 나타났다. 이에 반해 본 연구에서 제안된 클러스터링 기법은 별도의 입력변수 없이 보다 안정적인 클러스터를 생성할 수 있음을 확인하였다. 본 연구는 물체 추적에 낮은 오류율로 보다 신뢰성 있는 물체 클러스터를 제공할 수 있을 것이다.

References

- [1] M. A. Richards, Fundamentals of Radar Signal Processing, McGraw-Hill, 2005.
- [2] M. Skolnik, Radar Handbook, McGraw-Hill, 1990.
- [3] M. Skolnik, Introduction to Radar Systems, McGraw-Hill, 2001.
- [4] S. Lee, D. Choi, Y. Jung, S. Lee and J. Yoon, "Development of Target Signal Simulator for Multi-Beam Type FMCW Radar," Journal of the Korea Institute of Military Science and Technology, Vol. 15, No. 3, pp. 343-349, 2012.
- [5] K. Kim, "Pre-Clustering for Plot Formation on a Multi-Beam Radar," Agency of Defense Development Technical Report, ADDR-517-080649, 2008.
- [6] S. Kim and I. Lee, "Simulation Based Performance Assesment of a LIDAR Data Segmentation Algorithm," Journal of the Korea Society for Geospatial Information System, Vol. 18, No. 2, pp. 119-129, 2010.
- [7] A. Martone, K. Ranney and R. Innocenti, "Clustering Analysis of Moving Target Signatures," Proceedings of the SPIE, Vol. 7669, 2010.
- [8] P. S. Bradley and U. M. Fayyad, "Refining Initial Points for K-Means Clustering," In ICML, Vol. 98, pp. 91-99, 1998.
- [9] T. Kanungo, D. M. Mount, N. S. Netanyahu, C. D. Piatko, R. Silverman and A. Y. Wu, "An Efficient K-Means Clustering Algorithm : Analysis and Implementation," Pattern Analysis and Machine Intelligence, IEEE Transactions on, Vol. 24, No. 7, pp. 881-892, 2002.
- [10] C. Ding and X. He, "K-Means Clustering Via Principal Component Analysis", In Proceedings of the Twenty-First International Conference on Machine Learning, p. 29, 2004.
- [11] M. Steinbach, G. Karypis and V. Kumar, "A Comparison of Document Clustering Techniques," In KDD Workshop on Text Mining, Vol. 400, No. 1, pp. 525-526, 2000.
- [12] http://en.wikipedia.org/wiki/K-means_clustering